

Introdução ao Python e Web Scraping

Gabriel Sanábio Mazzetti Affonso

2026-08-21

Índice

Prefácio	3
1 Introdução	4
1.1 A importância do Python na Estatística	4
1.2 O escopo deste material	4
2 Configurando o Ambiente de Trabalho	6
2.1 O Ambiente <i>Python</i> e o pacote <i>reticulate</i>	6
2.2 Gerenciamento de Bibliotecas com o <i>pip</i>	6
2.3 Instalação Direta em Blocos de Código	6

Prefácio

O presente material consiste na consolidação dos resultados de pesquisa obtidos durante o período de Iniciação Científica, no contexto do projeto **Métodos de Aprendizado Estatístico para Discriminação e Classificação: Aplicações à Indústria 4.0 – Fase 3**. Este documento visa não só o detalhamento dos métodos de coleta de dados via *Web Scraping*, mas também a viabilidade do uso do *Python* para tal, além de destacar as especificidades da linguagem e suas vantagens para o aprendizado de métodos estatísticos e computacionais.

Neste contexto, vale ressaltar que o material é de cunho introdutório, buscando viabilizar o aprendizado do *Python* enquanto linguagem de programação e do *Web Scraping* como técnica poderosa de coleta de dados. Dessa forma, seu foco é desenvolver, no estatístico, o interesse pelos diversos recursos computacionais que podem auxiliá-los enquanto profissionais e estudiosos da área..

A motivação para o desenvolvimento deste material surgiu da necessidade de diversificar as ferramentas de aplicação computacional existentes para analisar dados. A interseção entre a teoria estatística e a aplicação dos métodos se sustenta no casamento entre o rigor matemático e a modernidade computacional. Qualquer das partes que for negligenciada ocasionará problemas ou limitações importantes.

Ademais, é válido ressaltar a seção extra presente no material, desenvolvida com o intuito de explicar a estrutura dos livros digitais, como esse, usando o *Quarto*. Ainda que muitos considerem adequado o uso do *Bookdown* para este tipo de trabalho (o que é totalmente válido, dadas as especificidades do Rmarkdown), o *Quarto* se mostrou uma espécie de sucessor natural muito adequado, apresentando ferramentas modernas e extremamente úteis para detalhes de *layout*, especialmente tratando de documentos compilados em *HTML*.

Por fim, deixo aqui minha gratidão à Universidade Federal de Juiz de Fora (UFJF) pelo ambiente acadêmico. Agradeço, especialmente, ao meu orientador, Professor Doutor Lupércio França Bessegato, pela oportunidade e pelo acompanhamento técnico que possibilitaram o desenvolvimento deste trabalho.

1 Introdução

Na prática, a estatística contemporânea vai muito além do domínio teórico dos fundamentos, da modelagem probabilística e da inferência. A sociedade atual convive com uma realidade em que os dados são o produto mais valioso existente, além simplesmente de fontes de informação. Dessa forma, observa-se nos últimos anos o surgimento de conceitos como o *Big Data*, para descrever o fenômeno da quantidade massiva de dados que alteram significativamente o fluxo de trabalho do analista de dados, exigindo deste profissional, muitas vezes, muito além da capacidade de analisar dados. É necessário ter aptidão para manusear os dados apropriadamente, buscá-los em diferentes fontes, criar filtros específicos relativos às necessidades de um determinado problema, entre outras habilidades.

Neste contexto, este material foi elaborado com o intuito de introduzir a linguagem *Python* no arsenal analítico de estudantes e profissionais de Estatística, demonstrando sua viabilidade e potência para a análise de dados e a automação de rotinas de trabalho.

1.1 A importância do Python na Estatística

Tradicionalmente, a linguagem *R* ocupa um lugar importante na formação do estatístico, por ser uma linguagem vetorizada e já desenvolvida para o trabalho com dados. Porém, apesar do poder do *R* e seus pacotes nos trabalhos de modelagem de dados e no uso de testes clássicos (paramétricos e não-paramétricos), o *Python* consolidou-se como uma linguagem extremamente versátil, que permite aplicações robustas (como as de *Machine Learning*, por exemplo) e a integração de sistemas.

Em termos de aprendizado, o *Python* é facilmente assimilado por quem já teve contato com algoritmos, por conta de sua similaridade com linguagens compiladas, como no caso do *C++* (exigindo apenas adaptações sintáticas), e com linguagens interpretadas, como o *R*.

Na prática, o *Python* apresenta sua maior vantagem ao analisarmos sua quantidade de usuários e, consequentemente, sua quantidade de bibliotecas desenvolvidas para diferentes aplicações. No contexto da Estatística, destacamos o *pandas*, para estruturação de dados tabulares, e o *numpy*, para computação numérica de alta performance. O domínio dessas ferramentas permite ao analista processar grandes volumes de dados com eficiência, além de explorar diferentes possibilidades, como a de romper com a dependência de bancos de dados pré-estruturados através da automatização da coleta de dados via *internet*.

1.2 O escopo deste material

Este material tem um teor introdutório e prático. Ele não tem a intenção de esgotar as funcionalidades do *Python* (que seria, inclusive, uma tarefa praticamente impossível), tampouco de aprofundar-se nas teorias estatísticas que fundamentam nossas análises ou na teoria computacional

que fundamenta e explica as especificidades da linguagem. O objetivo central é ser uma ponte rápida para profissionais de Estatística compreenderem a linguagem e o ecossistema, e como podem se beneficiar deles.

Neste âmbito, a abordagem adotada se resume em execução de códigos e análise de resultados práticos, de forma que o conhecimento seja construído sequencialmente, como se segue:

- Capítulo 2 - Configurando o Ambiente de Trabalho: Apresenta as instruções necessárias para preparar o ambiente de desenvolvimento, abordando a integração do *Python* dentro do *RStudio* (via pacote *reticulate*) e o gerenciamento de bibliotecas.
- Capítulo 3 - Fundamentos do *Python* para Análise de Dados: Revisa as operações básicas, tipos de dados e a criação de funções, estabelecendo a base sintática da linguagem.
- Capítulo 4 - Manipulação e Análise Exploratória de Dados: Introduz a biblioteca *pandas* e a criação de visualizações, utilizando conjuntos de dados clássicos (como *Titanic* e *Iris*) para demonstrar o tratamento e a exploração de informações categóricas e numéricas.
- Capítulo 5 - Computação Numérica com *NumPy*: Foca no uso de arrays multidimensionais e operações vetorizadas, ilustrando seu poder computacional através de simulações estatísticas.
- Capítulo 6 - Coleta de Dados via *Web Scraping*: Demonstra como construir bases de dados próprias automatizando a extração de informações de páginas da internet, sempre pautado por boas práticas e ética na raspagem de dados.
- Capítulo 7 - Estrutura de Livros Digitais (via *Quarto*): Explica brevemente a estrutura de arquivos e códigos para o desenvolvimento de livros digitais, utilizando o *Rmarkdown* para os códigos e textos e a ferramenta *Quarto* para a compilação.

Espera-se que, ao final deste conteúdo, o estudante ou profissional de Estatística sinta-se confortável para importar, manipular e coletar dados em *Python*, além de estar apto a construir livros digitais que podem ser ferramentas ainda mais robustas que os relatórios padrão, tendo base sólida para estudos posteriores mais aprofundados nestas ferramentas e suas possibilidades.

2 Configurando o Ambiente de Trabalho

Antes de iniciarmos a manipulação de dados e as análises, é fundamental garantir que o ambiente computacional esteja configurado corretamente. Para a maioria dos estudantes e profissionais de Estatística, o *RStudio* é o ambiente de desenvolvimento integrado (IDE) mais familiar. A boa notícia é que o *RStudio*, especialmente quando aliado ao *Quarto*, oferece um suporte excelente para a execução de códigos em *Python*.

2.1 O Ambiente *Python* e o pacote *reticulate*

Em alguns casos, especialmente na primeira execução de um script *Python* dentro do *RStudio*, o ambiente pode não estar perfeitamente configurado. Isso ocorre porque o *RStudio* utiliza um pacote chamado *reticulate* para fazer a ponte e integrar o *Python* ao ecossistema do *R*.

O *reticulate* pode acabar criando, de forma automática, um ambiente virtual *Python* próprio, isolado daquele que você eventualmente já tenha instalado em seu sistema operacional. Por conta desse isolamento, esse novo ambiente nem sempre possui todas as bibliotecas necessárias para a análise de dados já pré-instaladas.

2.2 Gerenciamento de Bibliotecas com o *pip*

Caso apareçam mensagens de erro indicando que bibliotecas fundamentais como *pandas*, *jupyter* ou outras não foram encontradas, elas podem ser facilmente adicionadas utilizando o *pip*. O *pip* é o gerenciador de pacotes padrão do *Python*, responsável por baixar, instalar e atualizar bibliotecas externas.

Para realizar a instalação via **Terminal** (aba **Terminal** no *RStudio*, e não no Console), basta executar os seguintes comandos:

```
python -m pip install pandas numpy seaborn matplotlib
python -m pip install jupyter
```

2.3 Instalação Direta em Blocos de Código

Em documentos interativos (como notebooks *Jupyter* ou arquivos *.qmd* do *Quarto*), também é possível executar comandos de terminal diretamente de dentro das células de código (*code chunks*). Para isso, utiliza-se o caractere de exclamação (!) no início da linha.

Por exemplo, o comando a seguir instala a biblioteca *pandas* diretamente a partir do ambiente de execução do documento, sem a necessidade de abrir o terminal do sistema:

```
!python -m pip install pandas
```

Dica importante: Caso o *RStudio* continue apresentando problemas ou pareça estar utilizando uma instalação do *Python* diferente da esperada, pode ser necessário reiniciar a sessão do *R* (*Session* > *Restart R*) para que o *reticulate* reconheça as novas bibliotecas instaladas. Em geral, após essa configuração inicial e a instalação dos pacotes, o código passará a funcionar normalmente.